

MULTIPLE SEQUENCE ALIGNMENT

SIMULATED ANNEALING

Nadia Olszewska 164211 - nadia.olszewska@student.put.poznan.pl
Małgorzata Pawlisiak 163776 - malgorzata.pawlisiak@student.put.poznan.pl
Bioinformatyka semestr III Lab gr. 1

Multiple Sequence Alignment(MSA) -> Dopasowanie wielu sekwencji polega na utworzeniu macierzy zawierającej sekwencje nukleotydowe i wyrównaniu różnic wynikających z mutacji poprzez wstawienie przerw(gapów) w celu uzyskania analizy podobieństwa, wyznaczenia sekwencji konsensusowej oraz oszacowania dystansu ewolucyjnego za pomocą odległości Levenshteina.

Złożoność obliczeniowa problemu MSA:

- Klasa problemów NP-trudnych
- $O(n^k)$ - k(ilość sekwencji), n(długość sekwencji)

Ze względu na mnogość operacji jakie algorytm musi wykonać, aby znaleźć wynik zaimplementowano metaheurystkę, która pozwala przeszukać przestrzeń rozwiązań w czasie wielomianowym, rezygnując z gwarancji znalezienia wyniku optymalnego na rzecz wyniku „wystarczająco dobrego”.

Generator instancji:

- **Sekwencja matka (Mother DNA):** Najpierw generowana jest losowa sekwencja o podanej przez długości len. Służy ona jako wzorzec ("prawda biologiczna"), do którego później porównujemy wynik (konsensus).
- **Proces mutacji:** Każda z sekwencji powstaje poprzez kopiowanie "matki" z określonym prawdopodobieństwem mutacji p.
 - **Substytucja:** Zamiana nukleotydu na inny.
 - **Insercja:** Wstawienie losowego nukleotydu(wydłużenie sekwencji).
 - **Delecja:** Usunięcie nukleotydu(skrócenie sekwencji).
- **Zastosowanie:** Dzięki takiemu podejściu znamy pierwotną sekwencję, co pozwala na obliczenie miary Levenshteina i procentowej jakości rekonstrukcji.
- Do generowania danych i mutacji wykorzystano silnik Mersenne Twister (mt19937) z biblioteki <random>, który zapewnia znacznie wyższą jakość statystyczną i dłuższy cykl losowości niż standardowa funkcja rand().

Algorytm Naiwny

- Algorytm naiwny pełni rolę generatora rozwiązania początkowego dla metaheurystyki.
- Znajduje najdłuższą sekwencję w zbiorze wejściowym, a wszystkie krótsze sekwencje dopełnia przerwami (gapami) na samym końcu, aż do wyrównania długości.
- Wynik algorytmu naiwnego jest przekazywany jako argument wejściowy do funkcji simulatedAnnealing.

Algorytm metaheurystyczny Simulated Annealing(SA):

- **Reprezentacja danych:**
 - Rozwiązanie reprezentowane jest przez strukturę **Alignment** zawierającą macierz (vector<vector<int>> M).
 - Wartości w macierzy: 0 reprezentuje przerwę(gap), a liczby 1,2,3,4 odpowiadają nukleotydom {A,C,G,T}.
 - Wiersze macierzy odpowiadają sekwencjom, a kolumny pozycją w dopasowaniu

- **ScoreAlignment:**
 - Funkcja pomocnicza obliczająca score dla aktualnego dopasowania.
 - Implementacja opiera się na modelu Sum-of-Pairs(SoP), co oznacza, że całkowity wynik jest sumą wyników dopasowań wszystkich możliwych par sekwencji w macierzy.
 - Match: +2, Mismatch: -1, Gap Open: -2, Gap Extend: -1, GapGap: -4.
 - Wprowadzenie kary GapGap jest kluczowe dla stabilności metaheurystyki. Bez niej algorytm dążyłby do rozwiązania zdegenerowanego(pustej macierzy), ponieważ suma kar za niedopasowania byłaby niższa niż dopasowanie samych przerw. Dzięki tej poprawce SA jest zmuszone do aktywnego poszukiwania korelacji między nukleotydami.
- **Implementacja SA:**
 - **Operatory Sąsiedztwa - Ruchy wykonywane przez algorytm:**
 - ◆ SWAP: Zamiana sąsiednich elementów w wierszu.
 - ◆ Wstawienie przerwy w losowe miejsce i usunięcie przerwy z końca wiersza(tylko jeśli na końcu jest 0).
 - ◆ Usunięcie przerwy ze środka i dodanie jej na koniec.
 - ◆ Przesunięcie całego bloku przerw w kolumnie dla losowo wybranych sekwencji.
 - **Kryterium Metropolis:**
 - ◆ W każdej iteracji losowany jest ruch(modyfikacja macierzy). O tym, czy nowe rozwiązanie(cand) zastąpi obecne (curr), decyduje $\Delta = \text{Score}_{\text{cand}} - \text{Score}_{\text{curr}}$.
 - ◆ Jeśli $\Delta > 0$: Nowe rozwiązanie jest lepsze - zawsze je akceptujemy.
 - ◆ Jeśli $\Delta \leq 0$: Nowe rozwiązanie jest gorsze - akceptujemy je tylko z określonym prawdopodobieństwem P, zgodnie ze wzorem:
$$P = e^{\frac{\Delta}{T}}$$
 - ◆ T to aktualna temperatura. Dzięki temu w początkowej fazie (wysokie T) algorytm może wyjść z optimum lokalnych, akceptując gorsze ruchy.
 - **Schemat Schładzania (Cooling)**
 - ◆ Zastosowano liniowy schemat chłodzenia, który synchronizuje spadek temperatury z czasem rzeczywistym zarezerwowanym na obliczenia:
$$T = T_{\text{start}} \times \left(1 - \frac{T_{\text{current}}}{T_{\text{limit}}}\right)$$
 - ◆ Start: $T = T_{\text{start}}$ (wysoka swoboda ruchów, eksploracja).
 - ◆ Koniec: T dąży do 0(algorytm przestaje akceptować błędy, udoskonala najlepszy znaleziony wynik).

GetConsensus: Wyznacza sekwencję wynikową poprzez "głosowanie" w kolumnach. Wybiera najczęściej występujący nukleotyd w danej kolumnie dopasowania.

CalculateLevenshtein: Oblicza minimalną liczbę edycji (zamian, wstawień, usunięć) potrzebnych do przekształcenia konsensusu w MotherDNA. Jest to obiektywna miara sukcesu algorytmu.

Porównanie działania algorytmu naiwanego i SA:

- **Wpływ czasu na jakość dopasowań: (instancja.txt)**
 - Parametry stałe sekwencji: ilość=8, długość=400, mutacje=0.1

Proba 1: Score = 7753
 Proba 2: Score = 8999
 Proba 3: Score = 8534
 Proba 4: Score = 8061
 Proba 5: Score = 7718
 Proba 6: Score = 7678
 Proba 7: Score = 8464
 Proba 8: Score = 8255
 Proba 9: Score = 8282
 Proba 10: Score = 8213

SREDNI SCORE: 8195.7
 NAJLEPSZY SCORE: 8999
 NAJGORSZY SCORE: 7678

Wyniki dla 60s:

Proba 1: Score = 5267
 Proba 2: Score = 5866
 Proba 3: Score = 5496
 Proba 4: Score = 5891
 Proba 5: Score = 5569
 Proba 6: Score = 6179
 Proba 7: Score = 6179
 Proba 8: Score = 5709
 Proba 9: Score = 5918
 Proba 10: Score = 6360


SREDNI SCORE: 5843.4
 NAJLEPSZY SCORE: 6360
 NAJGORSZY SCORE: 5267

Wyniki dla 10s:

Proba 1: Score = 1321
 Proba 2: Score = 1861
 Proba 3: Score = 2294
 Proba 4: Score = 1938
 Proba 5: Score = 1756
 Proba 6: Score = 2094
 Proba 7: Score = 2436
 Proba 8: Score = 2255
 Proba 9: Score = 3051
 Proba 10: Score = 2413

SREDNI SCORE: 2141.9
 NAJLEPSZY SCORE: 3051
 NAJGORSZY SCORE: 1321


Wynik dla 1s:



- **Wnioski:** Najwyższe uzyskane score to 8999. Algorytm naiwny jest niezależny od czasu, za każdym razem przybiera tą samą wartość. Algorytm SA wykazuje najsilniejszy przyrost jakości w pierwszych 12 sekundach. Powyżej 34 sekund następuje faza stabilizacji(plateau), co świadczy o osiągnięciu wysokiej jakości rozwiązania. W każdej chwili algorytm SA daje lepsze score niż zachłanny.

- Wpływ mutacji na jakość dopasowań: (instancja1.txt - instancja6.txt)


- Parametry stałe: ilość=6, długość=600, czas=10s



- **Wnioski:** Dla niskich wartości $p (< 0.05)$ algorytm odtwarza sekwencję konsensusową z bardzo dużą dokładnością. Wzrost p powyżej 0.1 powoduje drastyczny spadek jakości rekonstrukcji, mimo że algorytm wciąż znajduje wysoki Score.

- Wpływ mutacji na odległość Levenshteina: (instancja1.txt - instancja6.txt)


- Parametry stałe: ilość=6, długość=600, czas=10s



- **Wnioski:** Wraz ze wzrostem parametru p , odległość Levenshteina między konsensem a sekwencją Mother DNA rośnie w sposób nieliniowy. Zaobserwowano, że algorytm Simulated Annealing skutecznie minimalizuje ten dystans w porównaniu do metody naiwnej, jednak przy bardzo wysokich wartościach mutacji (duża liczba operacji indel), odnalezienie pierwotnego wyrównania staje się fizycznie niemożliwe ze względu na zatarcie sygnału biologicznego w danych wejściowych.

- **Wpływ mutacji na jakość rekonstrukcji: (instancja1.txt - instancja6.txt)**


- Parametry stałe: ilość=6, długość=600, czas=10s



- **Wnioski:** Wykres wykazuje silny związek między prawdopodobieństwem mutacji a jakością rekonstrukcji sekwencji pierwotnej. Dla niskich wartości p (poniżej 0.05), algorytm SA odtwarza sekwencję Mother DNA z dokładnością bliską 100%. Przy wzroście mutacji do poziomu $p=0.2$, jakość rekonstrukcji zbliża się do 50%. Sugeruje to, że gdy mutacji jest zbyt dużo, wysoki wynik punktowy (Score) przestaje oznaczać, że DNA jest dobrze odtworzone.

- **Wpływ ilości sekwencji na jakość dopasowań: (INS1.txt - INS5.txt)**

- Parametry stałe: długość=400, mutacje=0.05, czas=10s



- Wnioski: Zwiększenie liczby sekwencji wejściowych przy stałym p pomaga w wyznaczeniu lepszego konsensusu. Działa tu mechanizm głosowania większościowego - błędy występujące u pojedynczych osobników są niwelowane przez poprawną informację u pozostałych.

Przykład zapisu pełnego raportu do pliku:

roz: 1441
Odlugosc Levenshteina: 225
Jakosc rekonstrkcji: 43.75%

SEKWENCJE:
Oryginalne DNA (Mother):
GATCCACTCCGGCTGAGGAAGTTTGACAAACGCTCAGGTGAATGATGATGGGGGTGCTGCCATTCCCGCTCAAGTCTTGATGCTCTTCTACGACATAGGAACGGCAGCTGTGCTATGGACATGGGATACGCTCCAGCTGATGAGCATCTGTGCAGGTAGCTTGTAAATACATACCTCCCTCCGT
CTACGCGGGGAGTTCAGGAGAGTTTCCGCAATAAGAGGCTTCTCGGTAGAAGCAGCGCCGCGGAGTGGGATTTCTTCAACAATTTGATGAACCTTAACCTTAAAGCGGAACAGATGACGGGAGCGGTAAATTTCTTCAGGGTCCGCGGCATCGCAATCACGCTCCCGCGGACATCTAC
TTATTAAACAATGAGCCTGATGAGCTGAGT

Zrekonstruowane DNA (Consensus):
GCTTGAGCGGTAGTCTGATCGACGATTTATGCGCTATGCGCGGGGGGATACCTGTGCGCAGGATCATACGGGGGGGAGAACACCTTGCAAAAGTACTTGACATCATAGTGGGCTGCTTATCATTAAGGGGGGCTTTTTTGGTCTCACGATTTGGTTAAATACATTGCAGGGCCGCGAG
AAAAATTCATAGTTTACTGTCCAAACACCATTCGACAGCTGTGACTCAAGGGGTGGGGTAGGGAAGCTCCGAGATTTGAACCTGTGTGACCGCATGGCAAGAGATGACGGGGTCCAAATGTTGAGATATTGTACAGGGGACAGCCTTTTCGCAAGTTCCGTAGGGTGGGGCTGCGGG
GGAGCCGCTTCCGGTAGGTCGCACATCCAGTCCAG

DOPASOWANIE KONCOWE (Alignment):
CGTTGAGCGGTAGTCTGACAGCAGGATTATGACAGGGT-GAGTTACGCTGTGCGCAGGACTACACTGAGGGGACAGCCATTGGCAA-
GTTACTTGACATCATAGTGGGCTGCTCTATCATTAAGGGGTGGCTTTTTTGGTTCTCACGATTGGGTTAAATACATTGCAGCGGCAGATAAATTCAAATGCTGACTGTGACAAACACCTTGCAGAGCTGTGACTCCAAGGATATGGTACGGGAGGTGCAGAGATTTGAATCGTGTG
ACCGG-CATGACAGAGATGACG-GGGTCCCAAATGTTG-AGATATTGCTAGGGTACAGCTGTGCGGAAGTCTGTTGAGTGGCGGCTGTGTCGGTACGCTGCGGTACGCTTGGGTAGGTCCTCATTCAGTGGTCCCAATCGACCTCAGTCCAG
GCTTGGCGGTAGTCTGACGCGCAGGATTCTATGACCGGGTAGATCATGTCGCGCAGGATCATACGTGAGGGGGGAGCACTGTGCAAGTATGACATAGGTGGGTGCTCTATCATTAAGGGGTGGCTTTTTTGGTCTCACGATTTGGGTTAAATACATTACAAGGCCGCGAG
ATAAATTCACCTGGTCACTGTTCAAAACACACTTCCGACGTTGACTCCAAGGGACGGGTACGGGAGCGTCAAGGATTGGATCGGTTGACCGCATGGCAAGAGATGACGGGGTCCAAATGTTGAGATATTGTACAGGGTACAGCTGTGCGCAAGTCTGTTGAGTGCGGCTGTGTTG
GGTACTCTCTCAAGTAGGTCCTCATTCAGTCCAGTCCAGT

CGTTGAGCGGTAGTCTGACAGCAGGATTAAATGACAGGGTAGTACGCTGTGCGCAGGATCATACGTAGGGGACAGCCACTGTGCAA-
TGACTCTGCACATCATAGTAGGTTGCTCTATCATTAAGGGGTGGCTTTTTTGGTTCTCACGGAATTTGGGTTAAATACATTGCAGCGGCAGGATAAATTCAAATGCT-
ACCTGTCAAAACACCATTCGACAGCATGACTCCAAGGGTATGGGATGGGAGCTCAGAGATTGAAGCGGTGTGACTGCGCATGAGAAGAGAGTACGGGGTCCGAAATGTTGAGATATTGT-
CAGGGTAGTCTGTTGCGGCAAGTCTGTGTGAGTGCGGCTGTGCTGCGTACGCTTCCGTTAGGATCCACATCAGTCCAG
CGTTGAGCGGAGTGTACGACGAGGTTTATGACAGGGTG-AGTTACGCGTGTGCGCAGGATCATCCTGAGGGTGACAGCACTTGTCGAA-
GTTACTTGACATCACTGTTGGTGGCTGCTTATCATTAAGGGGTGGCTTTTTTGGTTCCAGATTGTGGTATATATCATTCGACGGCCCGCATATAATTCACATGGTA-
TGCTCAAAACACCATTCGACAGGTTTGAAGTCCAAAGGGTATGGGATCGGAGCGTCAAGATATGAACCGTGTGACCGCATGGCAAGAGATGACGGGGTCCAAATGTTGAGATATTGTACAGGGTACAGCTGTGCGCAAGTCTGTTGTTGGTGGCTGCTGTCGGTACCGCTTCGG-
CAGGTCACATCCAGTCCAGTCCAG

CGTTGAGCGGATTATTCACGCGAGGTTTATGACAGGGTG-AGTTACGCTGTGCGCAGTATCATGCTGAGGGGACAGCCACTGTGCAA-GTTACTTGACATCATAGTGGGCTGCTATCATTAAGGGGTGGCTTTTTTGGTCTCACGTTGGG-GTTAATACATCTG-
CAGCGCCGCAACCATTTCCAACTGCTCA-CGTGCTACGAGCATTCAGACAGTTGACTCCAAGGGTATAGGATCGGAGATGACGAGGATGAGGAGTCAAGGATTTGAATCGGTTGACCGGCTACG-
AAGAGATGACGGGGTCCCAAATGTTGAGGATTGTGACAGGTCAGCGTTGCTGTAAGTTGCTGTGAGTGCGGTTCGCTGACGCTTC-GGGAGT-C-CACATCAAGTCCAG
CGTTGAGCGGTAGTCTGACAGCAGATTATGCAAGGGT-
GAGTACGCTGTGCGCGAGGATCATAGTGAGGCGAGCAGACTGCAAGTTACTTGACATCATAGTGGGGTGCTCTATCATGTAAGAGGTTGGCTTTTTTGGTCTGACGATTGTGTTAAATACATTGCAGCGCCGAGATAAATTCAACTGCA-
CGTGTCAAAACACCATTCGGGAGCTGTGACTCCAAG-GTTGGGATCGGAGCTCAGAGATTGAATCGGCTATCGGATCGGAGATGACGGGTCCTCAAATGTTGAGA-TATTG-TACAGGTACAGATGTGCGCA-
AGTTGCTGAGGATGTGGGCTGTGATCGGATCTCTTCGTAAGTCCCAATCAGTCCAG
CGTTGAGCGGTAGGCTGTACGCGAGGATTATGACAGGGTAGTACGCTCTGTCGAGGATCATACGTGAGGGGACAGCCCTGTGCAAGTTACTTGACATCATTTGGTGGGCTGTGTATCATTAAGGGGTGGCTTTTTTGGTCTCACGATTGGGTTAAATTAACATGCAGCGGCTGCGAG
ATAAATTCAAATGCT-ACCTGTGCAAAACACATGACAGCATGAGCTCCAAGG-GATGTTGGTACGGGAGCTGCAAGGATTGAATCGGTTGATGCGG-CATGACAGGAAGATACGGGGTCCCAAATGTTAGATATTGTAGGTGACAGCTGTGTCGGCA-
AGTTGCTTGAAGTGCAGGGCTGTGCTGCGACGCTTCCGTTAG-GTCCACATCAGTCCAG
CGTTGAGCGAGTGTGCTGACGACGATTATGACAGGGTAGTACGCTGTGCGCAGGATCATACGTGAGGGGACAGCCACTGTGCAAGTATTCATGACATCAAGTGGGCTCTATCATCATTAAGGGGTGGCTTTTTTGGTCTTCTAC-ATGATGGGTTAAATTA-
CATTCGACAGTCCGCGAGCAATTTTCCAACTGCTA-CTGTGCAAGAACATCATGCGAG-ACGTTGACTCCAAGGATGAGGTAGGAGCATTAAGGACAGGATGTAACCGTTGACCGATGACCAAGAGATGACG-GTTCACAGGCTTCAG-
ATATTGTGACGGTACAGTGTGTCGGCAGATTTGCTGTGAGGGCGGCTGTGCTGCTGATCCGTTGCTGA-TGTCCACATCCAGTCCAG
CGTTTGAAGCGGTAGTGTGACGCGAGATTGTGCGGATGATGCTGCGTGGAGAGATGACCATCTGTCGAGCTCACTGACCTACAGTGGGCTGCTGTTACTTAAAGGGTGGCTTTTTTGGTCTCAACAATTTGGGTTAAATACATTGCAGCGGCTGCGAG
ATAAATTCACCTGCTACTGTGTCAAACACCATTCGACAGCTGTGACTCCAAGG-GATGTTGGTACGGGAGCTGACAGGATTTGATCGGTTGACCCATGACAGGAAGAGAGCG-GTCCCAAATGTTGAGATATTGTACGGGACAGCTGTGCGGCA-
TGCTGTGATGGTGGCTGCTGTCGGTACGCTTCCGAT-GGTTCAACATCAGTCCAG
CGTTGAGCGAGTATGCTGACCGCAGCTTTATGACAGGG-
TGAGTTGACGTTGCTGCGACGCTCATGAGTGGGGGACAGCAATGTGCAAGTTACTTGACATCATAGTGGGCTGCTCTATCATTAAGGTGGTGGCTTTTTTGGTCTCAACGATTGGGTTATTACATGCAGCGGCTGCAGATAAATTCAACTGCT-
ACCTGTCAAAACACCATTCGACAGCTGTGACTCCAAGGGTGTGGGATCGGAGGACTCAGAGATTGAATCCGTTGTCGACCGCCATGCAAGAGATGACGTGGTCCGAGCATAGA-
TATATTGTACGGGTACAGCTTTCGCGAAGTTCTGTGCTATTGGCGCTGTGCTGCGTACCGCTGCTGTAGGTGCCACATCCAGTCCAG
CGTTGAGCGGTAGTCTGACAGCAGGATTATGACAGGGT-
GGATTACGCTGTTGCGCAGATCATACGTGAGGGGACAGCACTGCAAGATTACTTGACATACATAGGTGTGCTGCTTACTTAAGGGTGGCTTTTTTGGTCTACCGATTGGGTTAAATACATTGCAGCGCACCTCAGATATATCAACTGCTACCTTGGTAAACACACTCGCAGA
CTTGACCTCAAGGATGTGTGACGGGAGAGGTCAGAAATTTGAATCGTGGTGGGCGCTAGACAGGAATGACGG-GTTCCAAATTTGAAGATTTGTACGGGTAAAGCTGTGTCGCAA-GTCTGTGAGTGGCGGCTGCTGGTTGGTACCGCTCGGTA-GGTCCC-ACTACACTCAG
TGTGAGCGGTAGTGTGACCGACGATTTATGACAGGGTG-AGTACGCTGCTGAGCAGGATCATACGTGAGGGTAGAGACACTGTGCAA-
GTGTTACTGACCTCATAGGTGGGCTGCTGTATCATTAAGGTGGCTTTTTTGGTCTCACGATTGGATGTAATTTGACTGCAGCGCCCGCAGATAAATTCAAATGCT-ACCTACTAAACACCATTCGAAGGTTGACTCCAAGGGTATGGGATC-
GGAGCGTGCAGATTGGAATCGGTTGTCGCGCATGACGAAGATGACGGGATCCCAATGTTAGGATATTGTGACGGGTACAGCTGTGTCGGCAA-GTCTGTTGAGTGGGCGCTGTGCTGGTACGCTTCCG-GAGTCCAGGATCACACGTGCG

Liczba sekwencji: 20
Dlugosc bazowa n: 400
Prawd. mutacji p: 0.05
Czas dzialania SA: 1 sek.

Problemy napotkane w trakcie tworzenia programu i ich rozwiązanie:

- **Problem 1: Degeneracja rozwiązania do pustej macierzy (Score = 0).**
 - **Przyczyna:** Brak kary za dopasowanie przerwy do przerwy sprawiał, że usunięcie wszystkich nukleotydów było wyceniane wyżej(0 pkt) niż dopasowanie z błędami(wyniki ujemne).
 - **Rozwiązanie:** Wprowadzenie parametru GapGap = -4, co uczyniło „pustą macierz” rozwiązaniem najgorszym z możliwych i wymusiło na algorytmie poszukiwanie realnych dopasowań nukleotydów.
- **Problem 2: Paradoks czasu(wyniki dla 1s lepsze niż dla 10s).**
 - **Przyczyna:** Wykorzystanie stałego współczynnika chłodzenia sprawiło, że przy dłuższych czasach temperatura spadała zbyt szybko względem liczby iteracji, zamrażając algorytm w lokalnym minimum.
 - **Rozwiązanie:** Zaimplementowanie liniowego schematu chłodzenia, który synchronizuje spadek temperatury z rzeczywistym czasem pracy procesora.
- **Problem 3: Wysoka entropia(chaos) przy starcie.**
 - **Przyczyna:** Zbyt wysoka temperatura startowa($T=2000$) powodowała, że algorytm przez większość czasu akceptował niemal każdy ruch, niszcząc strukturę dopasowania.
 - **Rozwiązanie:** Obniżenie T_{start} do poziomu 20 zapewniło stabilną zbieżność i precyzyjne dopracowywanie wyniku w końcowej fazie.

Wnioski:

- Zastosowanie SA pozwoliło na uzyskanie wyników dodatnich, podczas gdy algorytm naiwny generował wyniki silnie ujemne. Świadczy to o dużej skuteczności przyjętych operatorów ruchu w eliminowaniu kosztownych przerw.
- Testy pokazały, że parametry sterujące (temperatura startowa, schemat chłodzenia) są ważniejsze niż sam budżet czasowy. Obniżenie T_{start} z 2000 na 20 wyeliminowało fazę początkowego chaosu, pozwalając na stabilną optymalizację.
- Zwiększenie liczby sekwencji wejściowych przy stałym poziomie mutacji poprawia precyzję konsensusu. Mechanizm głosowania większościowego w kolumnach macierzy skutecznie odfiltrowuje losowe błędy pojedynczych sekwencji.
- Wysoki wynik punktowy (Score) nie zawsze oznacza 100% poprawności. W warunkach wysokiej mutacji algorytm może znaleźć sztuczne dopasowania, co wskazuje na potrzebę krytycznej analizy wyników MSA.

Źródła:

https://en.wikipedia.org/wiki/Simulated_annealing
<https://en.cppreference.com/w/cpp/numeric/random.html>
https://en.cppreference.com/w/cpp/numeric/random/mersenne_twister_engine.html
<https://pubmed.ncbi.nlm.nih.gov/7804875/>